

Análise Exploratória de Dados

Predição e Recomendação de Escalações no Cartola FC

Trabalho de Conclusão de Curso — FGV/EMAp
Gabriel Rodrigues de Deus Abad | Orientador: Prof. Moacyr Alvim H. B. da Silva
Campeonato Brasileiro 2026 | 18 Rodadas | Junho 2026

3,294	470	18	179	4.25
25% dos registros	prováveis em campo	rodadas do Brasileirão	jogos disputados	pts (amostra de treino)
Amostra de Treino	Jogadores Únicos	Rodadas Analisadas	Partidas	Pontuação Média

Este relatório apresenta a análise exploratória da base do Cartola FC referente às 18 primeiras rodadas do Campeonato Brasileiro 2026. As análises de pontuação (distribuições, séries temporais, custo-benefício, scouts e mando de campo) usam apenas a **população de treino**: atletas com status Provável que efetivamente entraram em campo (3,294 registros, 24.9% dos 13,215 registros totais; 3,812 estavam Prováveis). A seção de status permanece na base completa, para justificar esse recorte — o mesmo que o modelo preditivo utilizará.

5.1.1 Distribuição de Pontuações por Posição

A distribuição de pontuações varia substancialmente entre posições, refletindo diferenças fundamentais nos sistemas de scouts do Cartola FC. Ambos os painéis usam exclusivamente a população de treino — atletas Prováveis que entraram em campo —, alinhada ao que o modelo preditivo verá. O painel A mostra a densidade (violino) e o painel B o boxplot com entalhes (IC 95% da mediana). Zeros, quando ocorrem, são pontuações reais de quem jogou, não ausência de campo.




Figura 1 — Violinplot e boxplot com entalhes de pontuação por posição, restritos a atletas Prováveis que entraram em campo. Entalhes representam o IC 95% da mediana.

Posição	N	Média	Mediana	Desvio P.	P25	P75	Máx.	% Zeros
Goleiro	311.00	4.08	3.40	3.95	0.90	6.30	15.90	0.00
Lateral	475.00	4.79	4.30	4.04	1.70	7.05	19.00	3.79
Zagueiro	555.00	3.32	2.40	3.47	0.80	5.20	17.40	5.59
Meia	950.00	3.78	2.70	3.84	1.10	5.50	19.90	4.95
Atacante	691.00	4.92	3.20	4.87	1.50	7.70	26.00	2.03
Técnico	312.00	5.22	4.55	2.35	3.50	7.04	12.76	0.00

■ **Insight:** Técnicos apresentam a maior pontuação média (5.22 pts) na amostra de treino. Técnicos pontuam 5.22 pts em média, com 0.0% de zeros, pois sua pontuação depende do resultado coletivo. Atacantes exibem o maior desvio padrão (4.87 pts), confirmando a maior imprevisibilidade desta posição. Atacantes: média 4.92, desvio 4.87.

5.1.2 Análise Temporal de Desempenho

A evolução das pontuações ao longo das 18 rodadas revela a dinâmica competitiva do campeonato. O painel A ilustra as médias por rodada para cada posição de linha, enquanto o heatmap (painel B) permite identificar rodadas de alto e baixo desempenho coletivo, possivelmente associadas a congestionamentos de calendário, clássicos ou rodadas com muitos mandantes fortes.




Figura 2 — (A) Séries temporais de pontuação média por posição. (B) Heatmap de pontuação média: posições x rodadas.

Coefficiente de Variação da Pontuação por Rodada:

Rodadas 1–9:

Rd 1	Rd 2	Rd 3	Rd 4	Rd 5	Rd 6	Rd 7	Rd 8	Rd 9
4.37	4.50	4.86	4.01	4.43	3.72	4.13	4.22	4.59
90%	93%	93%	108%	91%	96%	97%	89%	97%

Rodadas 10–18:

Rd 10	Rd 11	Rd 12	Rd 13	Rd 14	Rd 15	Rd 16	Rd 17	Rd 18
3.95	4.17	4.31	4.27	4.18	3.92	4.05	4.35	5.13
87%	86%	95%	93%	97%	91%	104%	94%	92%

Média = pontuação média na amostra de treino (Provável e em campo); CV = coeficiente de variação (Std/Média × 100%).

■ **Insight:** A variabilidade das pontuações permanece alta mesmo na amostra de treino (CV entre 86% e 108%), refletindo a natureza assimétrica dos scouts. Rodadas com CV mais elevado podem indicar confrontos desequilibrados ou condições especiais de calendário, e serão consideradas na construção de features de contexto de rodada.

5.1.2b Autocorrelação de Séries Individuais (ACF / PACF)

Para informar a construção de features de lag, calculamos a Função de Autocorrelação (ACF) e a Função de Autocorrelação Parcial (PACF) das séries de pontuação individual. Três atletas representativos — um Atacante, um Meia e um Goleiro com alta regularidade na amostra de treino — são analisados. A série de cada atleta usa apenas as rodadas em que ele estava Provável e em campo; rodadas ausentes **não** são preenchidas com zero. As bandas sombreadas representam o intervalo de confiança de 95% sob a hipótese de ruído branco.




Figura 3 — ACF e PACF para séries de pontuação individual (apenas rodadas Provável e em campo). Lag refere-se à ordem cronológica dessas aparições. Lags significativos indicam dependência temporal.

■ **Insight:** A ACF de lag 1 tende a ser a mais relevante para a maioria dos atletas, sugerindo que a pontuação da rodada imediatamente anterior é o preditor temporal mais forte. A ausência de autocorrelação significativa em lags maiores na PACF justifica o uso de janelas curtas ($k = 3$ a 5 rodadas) nas médias móveis da engenharia de features, evitando overfitting a padrões de longo prazo inexistentes.

5.1.3 Análise de Custo-Benefício

O índice de custo-benefício (CB = pontos / cartoletas) quantifica a eficiência de cada atleta em termos de pontuação entregue por cartoleta investida. Identificar jogadores desvalorizados — aqueles com CB elevado e preço relativamente baixo — é o principal objetivo estratégico do Cartola FC. O painel A mostra a relação entre preço e pontuação; o painel B compara a distribuição do índice por posição; o painel C lista os Top 15 atletas por CB médio.




Figura 4 — (A) Scatter preço × pontuação por posição. (B) Distribuição do índice CB (pts/cartoleta) por posição. (C) Top 15 atletas por CB médio (mínimo 5 rodadas na amostra de treino).

Posição	CB Médio (pts/¢)	CB Mediana	Desvio P.	CB P75
Goleiro	0.538	0.504	0.539	0.874
Lateral	0.577	0.519	0.462	0.887
Zagueiro	0.499	0.410	0.503	0.802
Meia	0.508	0.409	0.478	0.778
Atacante	0.555	0.441	0.503	0.845

Insight: Laterals apresentam o maior CB médio (0.577 pts/¢) na amostra de treino. A correlação entre preço e pontuação é positiva mas não linear — existem bolsões de atletas baratos com alta pontuação, que o modelo de recomendação deverá identificar e explorar.

5.1.4 Correlação entre Scouts e Pontuação Final

A matriz de correlação entre cada scout individual e a pontuação final revela quais eventos de jogo têm maior poder explicativo sobre o desempenho, subsidiando diretamente a seleção de features. Calculamos os coeficientes de Pearson (sensível a relações lineares) e Spearman (robusto a distribuições não-normais e relações monotônicas), segmentando a análise em dois grupos posicionais com sistemas de scouts distintos. Marcadores de significância estatística: *** $p < 0.001$, ** $p < 0.01$.




Figura 5 — Correlações de Pearson e Spearman entre scouts individuais e pontuação total, segmentadas por grupo posicional. Ordenadas por valor absoluto da correlação de Spearman.

Scout	Spearman (At. & Meia)	Scout	Spearman (Def. & Gol.)
Gol (G)	0.240	Assist. (A)	0.162
Desarme (DS)	0.169	F.Sofrida (FS)	0.145
F.Sofrida (FS)	0.161	Gol (G)	0.119
F.Def. (FD)	0.155	Desarme (DS)	0.114

■ **Insight:** Para Atacantes e Meias, Gols (G) e Assistências (A) dominam a correlação — confirmando que os scouts ofensivos são os principais drivers de pontuação nesse grupo. Finalizações Fora (FF) e Faltas Sofridas (FS) aparecem como features secundárias relevantes. Para Defensores e Goleiros, Desarmes (DS) e Faltas Cometidas (FC) ganham importância relativa, embora as correlações absolutas sejam menores, refletindo a maior dependência coletiva do desempenho defensivo.

5.1.4b Matriz de Correlação Completa entre Scouts

O heatmap completo de correlação de Spearman entre todos os scouts e a pontuação final permite identificar também colinearidades entre features — essencial para a regularização dos modelos lineares (Ridge/Lasso). Pares de scouts com alta correlação entre si devem ser tratados com cuidado para evitar multicolinearidade.

Figura 8 — Matriz de Correlação entre Scouts e Pontuação




Figura 8 — Heatmap completo da correlação de Spearman entre scouts e pontuação, para Atacantes/Meias (esq.) e Defensores/Goleiros (dir.). Diagonal = 1. Escala: vermelho = positivo, azul = negativo.

■ **Insight:** Gol (G) e Assistência (A) mostram correlação positiva entre si (atacantes que chutam também assistem), sugerindo cuidado com multicolinearidade em modelos lineares. Cartão Amarelo (CA) e Falta Cometida (FC) têm correlação positiva esperada (infrações físicas). Para o grupo defensivo, Defesa (DE) e Sem Gol (SG) são altamente correlacionados — ambos capturam o desempenho do goleiro, tornando redundante usar os dois simultaneamente.

5.1.5 Análise de Mando de Campo

O mando de campo é um dos fatores mais consolidados na literatura de ciência do esporte. Nesta análise, associamos cada atleta ao papel de mandante ou visitante com base no cruzamento do seu clube_id com os dados de clube_casa_id por rodada. Aplicamos o teste t de Welch (variâncias independentes) para verificar significância estatística da diferença, controlando por posição.




Figura 6 — (A) Boxplot global mandante vs. visitante com resultado do teste t. (B) Diferença de pontuação média (Mandante – Visitante) por posição. (C) Violin por posição e mando. Significância: $^{***}p<0.001$, $^{**}p<0.01$, $^{*}p<0.05$.

Posição	Média Mand.	Média Visit.	Δ (M–V)	t-stat	p-valor	Signif.
Goleiro	4.392	3.769	+0.622	1.39	0.1651	n.s.
Lateral	5.382	4.197	+1.185	3.23	0.0013	**
Zagueiro	3.844	2.790	+1.054	3.61	0.0003	***
Meia	4.143	3.394	+0.749	3.02	0.0026	**
Atacante	5.451	4.373	+1.078	2.93	0.0035	**

■ **Insight:** 4 de 5 posições apresentam diferença mandante–visitante significativa ($\alpha=0,05$). Laterals apresentam o maior ganho absoluto em casa (+1.19 pts). A variável binária mandante/visitante será incluída como feature contextual nos modelos preditivos.

5.1.6 Análise de Status e Disponibilidade

O status do atleta na véspera da rodada é um dos preditores mais diretos da probabilidade de participação. O dataset registra cinco estados: Provável (7), Dúvida (6), Suspenso (5), Lesionado (3) e Não Participará (2). Esta seção usa a **base completa** e a coluna **entrou_em_campo** para medir participação efetiva — justificando o recorte da amostra de treino (Provável e em campo) adotado nas demais análises.




Figura 7 — (A) Volume de registros por status. (B) Pontuação média por status. (C) Taxa de participação em campo (coluna `entrou_em_campo`) por status. (D) Violin por status.

Status	N	Média (pts)	Desvio P.	% Zeros	% Participação
Provável	3812	3.68	4.00	16.4%	86.4%
Dúvida	7809	0.58	1.88	79.1%	24.9%
Suspenso	936	0.10	0.89	96.8%	4.1%
Lesionado	197	1.99	4.09	6.6%	93.4%
Não Participará	461	2.58	3.71	31.9%	74.2%

■ **Insight:** A taxa de participação cai drasticamente com o status. Atletas "Prováveis" entram em campo em 86.4% das rodadas, enquanto "Dúvida" cai para 24.9% e "Suspenso" para 4.1%. A diferença de pontuação média entre "Provável" (3.68 pts) e "Dúvida" (0.58 pts) é de magnitude 6.3x, tornando o status a variável de filtragem mais crítica: o modelo treina apenas em Provável e em campo, e o otimizador de escalação deve excluir ou penalizar status piores.

Síntese dos Achados e Implicações para Modelagem

- **Amostra de treino = Provável e em campo:** As análises de pontuação restringem-se a atletas que estavam Prováveis e efetivamente entraram em campo — a mesma população que o modelo preditivo utilizará. Zeros, quando existem, são pontuações reais, não ausência de participação.
- **Padrões temporais de curto alcance:** A ACF/PACF, calculada sem imputar zeros em rodadas ausentes, indica dependência temporal predominantemente de lag 1–2, justificando janelas de médias móveis de 3 a 5 rodadas. Features de longo prazo têm valor marginal decrescente.
- **Scouts ofensivos como principais drivers:** Gol (G) e Assistência (A) dominam a correlação com a pontuação para Atacantes e Meias. O sistema de features deve priorizar médias históricas desses scouts, especialmente contra adversários permeáveis.
- **Efeito mandante como feature contextual:** A variável binária mandante/visitante deve ser incluída nos modelos como feature de contexto de partida.
- **Status como filtro de escalação, não como feature de treino:** Atletas com status "Dúvida" ou pior devem ser excluídos ou fortemente penalizados no otimizador de escalação. A Figura 7 (base completa) justifica esse recorte; o modelo de pontuação não precisa classificar participação.
- **Custo-benefício como feature econômica:** O índice CB histórico e a tendência de valorização do jogador (`variacao_num`) serão features relevantes para o problema de otimização de escalação dentro do orçamento.

Nota metodológica: As análises de pontuação (seções 5.1.1–5.1.5) usam apenas atletas com status Provável que entraram em campo. A seção 5.1.6 usa a base completa para justificar esse recorte. Dados: Rodadas 1–18 do Campeonato Brasileiro 2026 (API pública do Cartola FC e `games.csv`). Testes de hipótese utilizaram $\alpha = 0,05$.